

Mini Project – Machine Learning: Klasifikasi Tingkat Keparahan Penyakit Alzheimer Berdasarkan Citra Otak

Anggota:

[202210370311236 – M. Ikbar Ananda Sulistio]

[202210370311237 – Dimas Arief Wicaksono]

[202210370311260 – Rofiq Samanhudi]

Latar Belakang

Penyakit Alzheimer merupakan salah satu bentuk utama demensia yang menyebabkan penurunan fungsi kognitif secara progresif, meliputi gangguan memori, kemampuan berpikir, dan perilaku. Jumlah penderita Alzheimer terus meningkat seiring bertambahnya usia harapan hidup, sehingga deteksi dini terhadap tingkat keparahan penyakit ini menjadi sangat penting agar penanganan dapat dilakukan secara tepat waktu. Proses diagnosis biasanya dilakukan melalui pemeriksaan klinis dan analisis citra otak seperti MRI atau CT scan, namun penentuan tingkat keparahan secara manual masih memerlukan waktu lama dan bergantung pada keahlian dokter, yang dapat menimbulkan subjektivitas. Dengan kemajuan teknologi kecerdasan buatan dan pembelajaran mesin, kini dimungkinkan untuk mengembangkan sistem klasifikasi otomatis yang mampu mengenali pola pada citra otak penderita Alzheimer secara lebih objektif dan akurat.

Tujuan

1. Membangun model klasifikasi otomatis yang mampu mengidentifikasi dan mengelompokkan tingkat keparahan penyakit Alzheimer berdasarkan citra otak menggunakan MRI
2. Mengklasifikasikan pasien ke dalam empat kategori tingkat keparahan, yaitu:
 - a. No Impairment (Tidak Ada Gangguan)
 - b. Very Mild Impairment (Gangguan Sangat Ringan)
 - c. Mild Impairment (Gangguan Ringan)
 - d. Moderate Impairment (Gangguan Sedang)

A. Explanatory Data Analysis

Tahap 1: Original Data

Dataset Alzheimer Detection digunakan untuk mendeteksi tingkat keparahan Alzheimer berdasarkan citra MRI otak. Dataset ini diperoleh dari Roboflow dengan total 9.766 gambar yang terbagi ke dalam empat kelas utama:

Tabel 1. Jumlah Data

Kelas	Jumlah Gambar	Persentase Data
No Impairment	2.767	28.33%
Very Mild Impairment	2.518	25.78%
Mild Impairment	2.264	23.18%
Moderate Impairment	2.217	22.70%

Seluruh gambar memiliki resolusi rata-rata 640×640 piksel dengan mode warna RGB. Distribusi antar kelas relatif seimbang, sehingga tidak memerlukan oversampling atau undersampling ekstrem.

Tahap 2: Data Pre-processing

Tahap ini berfokus pada proses penyiapan data citra agar siap digunakan dalam analisis dan pelatihan model. Citra MRI yang diperoleh dari berbagai sumber sering kali memiliki perbedaan ukuran, kontras, serta tingkat pencahayaan yang dapat memengaruhi performa model. Oleh karena itu, dilakukan serangkaian langkah *pre-processing* untuk menyeragamkan dan meningkatkan kualitas data.

Melalui proses ini, citra diubah ke ukuran standar, ditingkatkan kontrasnya agar struktur otak lebih jelas, serta dinormalisasi intensitas pikselnya agar perbedaan antar gambar tidak terlalu ekstrem. Selain itu, dilakukan augmentasi data untuk memperluas variasi sampel dan mencegah *overfitting* selama pelatihan. Dataset juga dibagi secara proporsional agar proses *training*, *validation*, dan *testing* dapat berjalan seimbang.

a. Standarisasi Ukuran Gambar

Seluruh gambar diubah ukurannya menjadi 224×224 pixel agar mampu menjaga keseimbangan antara detail visual dan efisiensi komputasi tanpa mengubah proporsi informasi penting pada citra, jadi 224 pixel:

- Cukup besar untuk mempertahankan detail visual penting.
- Cukup kecil untuk mengurangi beban komputasi (waktu training dan memori GPU).

b. Peningkatan Kualitas Data

Untuk memperjelas struktur dan pola pada citra MRI, digunakan metode Contrast Limited Adaptive Histogram Equalization (CLAHE). Metode ini meningkatkan kontras pada area lokal tanpa memperkuat noise secara berlebihan, sehingga detail jaringan otak lebih mudah dikenali oleh model. Hasilnya, citra setelah preprocessing memiliki tampilan yang:

- Lebih terang dan kontras seimbang.
- Struktur otak lebih terlihat jelas dibandingkan sebelum diproses.
- Perbedaan antar kelas lebih mudah diamati secara visual.

c. Normalisasi Intensitas

Semua nilai piksel dinormalisasi ke rentang $[0,1]$ untuk mempercepat konvergensi selama pelatihan dan mencegah ketimpangan nilai antar channel warna.

d. Augmentasi Data

Untuk meningkatkan variasi dan mengurangi overfitting, dilakukan augmentasi citra pada subset data training. Teknik augmentasi yang diterapkan meliputi:

- Rotasi acak hingga 15 derajat
- Pergeseran horizontal dan vertikal hingga 5%
- Zoom in/out hingga 10%
- Flip horizontal dan vertikal
- Penyesuaian tingkat kecerahan (brightness) antara 0.8–1.2

Augmentasi ini membantu model mengenali pola otak dari berbagai orientasi dan kondisi pencahayaan.

e. Pembagian Dataset

Dataset dibagi menjadi tiga subset dengan proporsi:


- Training: 5.859 gambar (59.99%)
- Validation: 1.953 gambar (20.00%)
- Testing: 1.954 gambar (20.01%)

Pembagian dilakukan secara stratified, sehingga proporsi tiap kelas tetap seimbang di setiap subset.

f. Visualisasi Hasil

Visualisasi dilakukan untuk melihat perbandingan antara citra sebelum dan sesudah preprocessing. Hasil pengamatan menunjukkan bahwa:

- Setelah penerapan CLAHE, tekstur dan pola pada area otak lebih menonjol.
- Distribusi warna menjadi lebih natural dan tidak terlalu gelap.
- Tidak ditemukan distorsi signifikan akibat proses resizing ke 224×224.



Gambar 1. Output hasil Preprocessing

g. Preprocessing Automation dan Pembagian Dataset

Setelah proses preprocessing selesai, seluruh citra dibagi menjadi tiga subset utama, yaitu *training*, *validation*, dan *testing*. Tahapan ini dilakukan agar model dapat dilatih, divalidasi, dan diuji menggunakan data yang terpisah sehingga menghindari *data leakage*. Langkah-langkah yang dilakukan pada tahap ini meliputi:

- Pembuatan struktur folder otomatis untuk setiap subset dan kelas.
- Setiap citra diproses kembali melalui fungsi `preprocess_image()` untuk memastikan semua gambar memiliki ukuran dan format yang seragam.
- Gambar hasil preprocessing disimpan pada folder sesuai subset dan labelnya.
- Penggunaan progress bar (tqdm) untuk memantau progres pemrosesan setiap subset.

B. Machine Learning Klasik

Machine Learning klasik adalah pendekatan pembelajaran mesin yang menggunakan algoritma statistik dan matematika tanpa melibatkan arsitektur jaringan saraf dalam yang sangat kompleks seperti pada deep learning. Model-model ini biasanya bekerja dengan jumlah parameter yang relatif kecil dan sangat bergantung pada rekayasa fitur (feature engineering) untuk memperoleh performa terbaik. Contoh metode machine learning klasik mencakup Logistic Regression, Support Vector Machine (SVM), K-Nearest Neighbors (KNN), Naive Bayes, Decision Tree, Random Forest, hingga algoritma boosting seperti XGBoost dan LightGBM.

Dalam machine learning klasik, performa model sangat dipengaruhi oleh kualitas representasi fitur yang diberikan. Karena algoritmanya tidak otomatis mengekstraksi fitur dari data mentah, maka kualitas input (misalnya tekstur, warna, statistik citra, atau vektor numerik lainnya) akan menentukan seberapa baik model dapat melakukan klasifikasi atau prediksi. Oleh karena itu, sebelum melatih model klasik, diperlukan tahap feature extraction untuk mengubah citra atau data mentah menjadi representasi numerik yang informatif.

Tahap 1: Feature Extraction

Pada tahap ini, dilakukan feature extraction untuk menghasilkan fitur-fitur yang dapat dikenali dan dimanfaatkan oleh algoritma machine learning klasik. Fitur inilah yang menjadi dasar pembelajaran, karena model klasik tidak secara otomatis mempelajari pola dari data mentah seperti yang dilakukan CNN atau Transformer. Dengan demikian, proses ekstraksi fitur merupakan langkah kunci untuk memastikan model dapat memahami struktur penting dalam gambar sebelum masuk ke tahap klasifikasi.

Fitur yang diekstraksi dapat dikelompokkan menjadi beberapa jenis, seperti fitur tekstur (contoh: LBP, GLCM, dan Wavelet), fitur bentuk (contoh: Zernike Moment dan Hu Moment), serta fitur global (misalnya HOG dan GIST). Setiap metode memiliki keunggulan tersendiri dalam menggambarkan aspek tertentu dari citra. Dengan memilih kombinasi fitur yang tepat, sistem analisis dapat mencapai hasil yang lebih akurat dalam mendeteksi, mengklasifikasikan, dan mengevaluasi kondisi jaringan berdasarkan informasi visual yang terkandung di dalam citra.

a. LBP (Local Binary Pattern)

Metode LBP digunakan untuk mengekstraksi fitur tekstur pada citra MRI otak dengan cara membandingkan nilai intensitas piksel pusat dengan piksel-tetangganya. Untuk setiap titik pusat, pixel yang memiliki intensitas lebih besar atau sama diberi nilai 1 dan lebih kecil diberi nilai 0, lalu rangkaian nilai biner tersebut dikonversi menjadi angka desimal yang kemudian dirangkum menjadi histogram. Dengan histogram ini, pola tekstur local, misalnya pola granularitas jaringan atau perubahan halus di jaringan otak, dapat direpresentasikan secara numerik. Dalam penggunaan pada Alzheimer, fitur-LBP membantu membedakan jaringan otak yang sehat dari yang mulai mengalami perubahan degeneratif berdasarkan pola teksturnya.

b. HOG (Histogram of Oriented Gradients)

Metode HOG digunakan untuk mengekstraksi fitur bentuk dan tepi dari citra MRI otak dengan cara menghitung distribusi arah gradien pada setiap bagian kecil citra. Secara sederhana, HOG bekerja dengan membagi citra menjadi beberapa sel kecil, lalu menghitung arah dan kekuatan perubahan intensitas piksel di dalamnya. Nilai arah gradien tersebut kemudian disusun menjadi histogram yang mewakili pola tepi atau kontur objek. Pada penelitian Alzheimer, HOG membantu mengenali perubahan struktur otak seperti penyusutan area tertentu atau pola permukaan yang tidak normal pada jaringan otak, yang sering menjadi indikator awal penyakit ini. Keunggulan HOG adalah kemampuannya menangkap informasi bentuk tanpa dipengaruhi oleh perubahan pencahayaan atau rotasi kecil pada citra.

c. Zernike moment

Metode Zernike Moments digunakan untuk mengekstraksi fitur bentuk global dari citra MRI otak dengan cara menghitung momen berdasarkan polinomial Zernike yang ortogonal dalam lingkaran satuan. Citra di-resize agar sesuai dengan radius yang ditetapkan, kemudian dibinerisasi dan dipetakan ke sistem koordinat polar sebelum dihitung momen Zernike hingga derajat tertentu. Dengan proses ini, Zernike Moments menghasilkan representasi numerik yang menggambarkan bentuk, simetri, dan struktur global dari jaringan otak, dan bersifat invarian terhadap rotasi objek.

d. Wavelet Features

Metode Wavelet Features digunakan untuk mengekstraksi informasi tekstur dan pola pada citra otak melalui dekomposisi wavelet di beberapa level skala dan frekuensi. Citra diubah ukurannya ke resolusi standar, kemudian melalui transformasi wavelet (misalnya “haar”, “db4”, “sym5”, “coif1”) hingga beberapa level. Hasil dekomposisi menghasilkan koefisien pada sub-band frekuensi rendah dan tinggi. Dari setiap sub-band tersebut diambil statistik dasar, seperti rata-rata (mean), simpangan baku (std), skewness, dan kurtosis yang kemudian digabung menjadi vektor fitur. Dengan demikian, fitur ini menangkap variasi tekstur dan pola lokal maupun global pada jaringan otak.

Dalam konteks Alzheimer, fitur wavelet sangat berguna untuk mendeteksi perubahan halus pada struktur jaringan otak seperti materi abu-abu dan putih, maupun pola intensitas yang berubah akibat degenerasi.

e. GLCM (Gray Level Co-occurrence Matrix)

Metode GLCM digunakan untuk mengekstraksi fitur tekstur lanjutan dengan cara menghitung seberapa sering sepasang piksel dengan nilai keabuan tertentu muncul bersama dalam citra, dengan jarak dan arah yang telah ditetapkan. Matriks co-occurrence ini kemudian dianalisis untuk menghasilkan fitur statistik seperti *contrast*, *correlation*, *energy*, dan *homogeneity*, yang mencerminkan keteraturan, kekasaran, atau keragaman pola keabuan dalam jaringan otak. Dalam penerapan pada citra MRI otak, GLCM membantu melihat perubahan tekstur jaringan yang mungkin terjadi pada kondisi Alzheimer, sebagai contoh, perubahan pola distribusi intensitas yang menandakan degenerasi jaringan.

f. FFT (Fast Fourier Transform)

Tujuan penggunaan Fast Fourier Transform (FFT) adalah untuk mengenali pola frekuensi spasial dari citra, yang merepresentasikan variasi intensitas cahaya di dalam gambar. Dengan mengubah citra dari domain spasial ke domain frekuensi, FFT membantu mendeteksi perbedaan tekstur dan struktur yang mungkin tidak tampak jelas pada tampilan citra asli. Dalam konteks analisis citra medis, informasi frekuensi ini berguna untuk membedakan pola morfologi jaringan atau kelainan, seperti perubahan tekstur pada organ atau area lesi.

g. GIST Descriptors

Fitur GIST digunakan untuk menangkap representasi global dari struktur dan tata letak suatu citra, bukan hanya detail lokal. Dengan memanfaatkan filter Gabor pada berbagai orientasi dan skala, GIST mengekstraksi informasi tekstur, arah, dan frekuensi spasial dari berbagai bagian citra. Dalam konteks analisis citra medis, fitur ini membantu mengenali pola morfologi keseluruhan organ atau jaringan, seperti perbedaan bentuk, tekstur umum, dan distribusi struktur yang menjadi indikasi kondisi normal atau gangguan kognitif.

Keunggulan GIST terletak pada kemampuannya menyederhanakan citra kompleks menjadi vektor fitur berukuran tetap yang tetap mempertahankan informasi spasial global.

h. Hu Moment

Fitur Hu Moments digunakan untuk menggambarkan bentuk atau kontur dari suatu objek dalam citra. Metode ini didasarkan pada invariant moments yang diperkenalkan oleh Hu (1962), yang memiliki sifat tidak berubah terhadap rotasi, translasi, dan skala. Dengan kata lain, bentuk objek akan tetap dikenali meskipun posisinya berpindah, ukurannya berubah, atau diputar dalam citra. Dalam analisis citra medis, Hu Moments sangat berguna untuk mengenali struktur anatomi seperti batas organ, lesi, atau tumor berdasarkan pola bentuk dan distribusi intensitas piksel.

Setiap metode ekstraksi fitur yang digunakan memiliki karakteristik dan fokus yang berbeda dalam menangkap informasi dari citra MRI otak. Oleh karena itu, seluruh metode tersebut diuji secara terpisah untuk melihat kemampuan masing-masing dalam mengenali pola, tekstur, dan bentuk yang berkaitan dengan tingkat gangguan kognitif. Pendekatan ini memungkinkan penilaian yang lebih objektif terhadap efektivitas setiap metode dalam menghasilkan representasi citra yang informatif bagi proses klasifikasi.


Tahap 2: Training Model

Tahapan ini merupakan proses pelatihan model klasifikasi menggunakan data fitur yang telah diekstraksi sebelumnya dari citra MRI, yang meliputi fitur Local Binary Pattern (LBP), Histogram of Oriented Gradients (HOG), Zernike Moment, Wavelet Features, Fast Fourier Transform (FFT), Gray Level Co-occurrence Matrix (GLCM), GIST Descriptors, dan Hu Moment. Setiap metode ekstraksi menghasilkan representasi numerik dengan karakteristik yang berbeda, yang kemudian digunakan secara terpisah untuk membangun model pembelajaran mesin.

Dalam penelitian ini digunakan algoritma Extreme Gradient Boosting (XGBoost) sebagai model utama untuk klasifikasi. XGBoost merupakan algoritma berbasis ensemble learning yang menggabungkan sejumlah pohon keputusan (decision trees) secara bertahap melalui mekanisme gradient boosting. Setiap pohon baru dibangun untuk memperbaiki kesalahan prediksi dari pohon-pohon sebelumnya, sehingga model akhir memiliki kemampuan prediksi yang lebih akurat. Pendekatan ini memungkinkan XGBoost menangkap hubungan non-linear antarfitur dan memberikan hasil yang stabil bahkan pada data dengan dimensi tinggi.

Proses pelatihan model dilakukan dengan parameter utama, antara lain jumlah pohon ($n_estimators$) sebanyak 500, kedalaman maksimum pohon (max_depth) sebesar 7, dan laju pembelajaran ($learning_rate$) sebesar 0.1. Selain itu, digunakan nilai $subsample$ dan $colsample_bytree$ sebesar 0.8 untuk meningkatkan kemampuan generalisasi dan mencegah overfitting. Selama proses pelatihan, model mencatat nilai log loss pada data pelatihan dan validasi di setiap iterasi untuk memantau konvergensi serta stabilitas model.

Model XGBoost yang telah dilatih kemudian disimpan bersama *scaler* dan *label encoder* untuk digunakan pada tahap evaluasi dan prediksi selanjutnya. Hasil pelatihan juga mencakup nilai *log loss* dan *approximate accuracy* yang direkam di setiap iterasi, sehingga dapat divisualisasikan untuk menilai konvergensi model serta mendeteksi potensi *overfitting* pada data validasi.



Gambar 2. plot akurasi dan loss dari hasil training model

Perbandingan kinerja model XGBoost berdasarkan jenis fitur yang digunakan ditunjukkan pada gambar 2. Grafik sebelah kiri menunjukkan bahwa hampir semua model mengalami peningkatan akurasi yang cukup cepat pada tahap awal iterasi. Setelah sekitar seratus iterasi, akurasi cenderung stabil. Akurasi validasi yang lebih tinggi ditunjukkan oleh fitur tertentu, seperti Zernike, FFT, dan HOG, dibandingkan dengan fitur lainnya, ini menunjukkan bahwa fitur-fitur ini lebih representatif dalam membantu model mengenali pola data. Grafik di sisi kanan menunjukkan nilai logloss, menurun secara signifikan pada awal pelatihan dan kemudian stabil di nilai yang lebih rendah, yang menunjukkan bahwa pembelajaran berjalan dengan baik. Secara keseluruhan, hasil ini menunjukkan bahwa XGBoost dapat belajar dengan baik pada semua jenis fitur, meskipun tingkat stabilitas dan performa akhir bervariasi antar jenis fitur.

Tahap 3: Evaluasi

a. Classification Report

Setelah model dilatih, dilakukan tahap evaluasi untuk mengukur seberapa baik model tersebut mengenali dan mengklasifikasikan citra MRI dengan benar. Beberapa metrik yang umum digunakan adalah:

- Accuracy (Akurasi): Mengukur seberapa besar persentase prediksi yang benar dari seluruh data uji.
- Precision: Seberapa banyak hasil positif yang diprediksi benar-benar positif.
- Recall: Seberapa banyak data positif yang berhasil terdeteksi oleh model.
- F1-Score: Merupakan rata-rata harmonik antara precision dan recall, sehingga lebih baik digunakan untuk menilai performa pada dataset yang tidak seimbang.

Tabel 2. Evaluasi performance

Feature Extraction	Training Model	Class	Precision (%)	Recall (%)	F1-Score (%)	Accuracy (%)
LBP	XG-Boost	Mild Impairment	83	65	73	69
		Moderate Impairment	97	96	97	
		No Impairment	55	73	63	
		Very Mild Impairment	52	45	48	

HOG	XG-Boost	Mild Impairment	98	84	91	89
		Moderate Impairment	100	99	99	
		No Impairment	79	93	86	
		Very Mild Impairment	84	79	80	
Zernike Moment	XG-Boost	Mild Impairment	78	78	78	80
		Moderate Impairment	98	98	98	
		No Impairment	76	78	77	
		Very Mild Impairment	72	69	71	
Wavelet Features	XG-Boost	Mild Impairment	93	70	80	77
		Moderate Impairment	98	98	98	
		No Impairment	61	85	71	
		Very Mild Impairment	69	55	62	
GLCM	XG-Boost	Mild Impairment	95	83	88	86
		Moderate Impairment	100	97	99	
		No Impairment	78	88	83	
		Very Mild Impairment	78	78	78	
FFT	XG-Boost	Mild Impairment	89	75	81	78

		Moderate Impairment	100	99	99	
		No Impairment	65	83	73	
		Very Mild Impairment	68	58	63	
GIST Descriptors	XG-Boost	Mild Impairment	98	91	94	93
		Moderate Impairment	100	100	100	
		No Impairment	87	95	91	
		Very Mild Impairment	90	86	88	
Hu Moment	XG-Boost	Mild Impairment	95	87	91	89
		Moderate Impairment	100	98	99	
		No Impairment	81	92	86	
		Very Mild Impairment	83	78	80	

Berdasarkan hasil evaluasi performa model XGBoost dengan berbagai metode ekstraksi fitur, terlihat bahwa setiap metode memiliki tingkat akurasi dan kemampuan klasifikasi yang berbeda terhadap empat kelas kondisi kognitif, yakni :

- No Impairment
- Very Mild Impairment
- Mild Impairment
- Moderate Impairment

Secara keseluruhan, Gist Descriptor dan Hu Moment memiliki performa terbaik dengan nilai akurasi keseluruhan masing-masing mencapai 93% dan 89%. Kedua metode ini memiliki nilai *precision*, *recall*, dan *F1-score* yang tinggi di hampir semua kelas, terutama pada kelas Moderate Impairment dan No Impairment yang mencapai nilai mendekati sempurna. Hal ini menunjukkan bahwa kedua fitur mampu menangkap representasi pola citra lebih baik dari sisi tekstur maupun bentuk global.

Metode HOG, GLCM, dan Zernike juga menunjukkan performa yang cukup baik dengan akurasi di atas 80%. HOG memiliki kekuatan pada deteksi detail tekstur dan tepi yang efektif untuk membedakan antar kelas, dengan nilai *F1-score* rata-rata di atas 85%. GLCM menampilkan keseimbangan antara *precision* dan *recall*, menandakan kemampuan yang stabil mengenali pola spasial antar piksel. Sedangkan Zernike memiliki nilai akurasi yang tinggi pada kelas Moderate Impairment. Metode LBP dan Wavelet Features menunjukkan performa yang lebih rendah dibandingkan metode lainnya. Pada kelas Very Mild Impairment, di mana nilai *recall* dan *F1-score* cenderung menurun. Hal ini menandakan bahwa fitur yang dihasilkan dari metode tersebut kurang mampu menangkap variasi halus antar kategori yang mirip secara visual.

Secara keseluruhan, dapat disimpulkan bahwa fitur berbasis GIST Descriptors menangkap karakteristik visual yang terkait dengan tingkat gangguan kognitif dengan paling efektif, diikuti oleh HOG dan Hu Moment. Sementara itu, fitur seperti LBP dan Wavelet cenderung kurang efektif dalam membedakan kelas dengan perbedaan yang lebih kompleks.

b. Error Analysis

Error analysis dilakukan untuk memahami sejauh mana model XGBoost melakukan kesalahan dalam klasifikasi pada masing-masing jenis fitur dan kelas. Tujuan dari analisis ini adalah untuk mengetahui pola kesalahan yang muncul serta mengetahui kelas mana yang paling sering salah di prediksi oleh model.

Tabel 3. Error Analysis

Feature Extraction	Class	Total	Misclassified	% Error
LBP	Mild Impairment	453	159	35.10%
	Moderate Impairment	444	18	4.05%
	No Impairment	553	150	27.12%
	Very Mild Impairment	503	279	55.47%
HOG	Mild Impairment	453	72	15.89%
	Moderate Impairment	444	4	0.90%
	No Impairment	553	39	7.05%
	Very Mild Impairment	503	104	20.68%
Zernike Moment	Mild Impairment	453	99	21.85%
	Moderate Impairment	444	8	1.80%
	No Impairment	553	122	22.06%

	Very Mild Impairment	503	155	30.82%
Wavelet Features	Mild Impairment	453	137	30.24%
	Moderate Impairment	444	11	2.48%
	No Impairment	553	83	15.01%
	Very Mild Impairment	503	224	44.53%
GLCM	Mild Impairment	453	78	17.22%
	Moderate Impairment	444	12	2.70%
	No Impairment	553	65	11.75%
	Very Mild Impairment	503	111	22.07%
FFT	Mild Impairment	453	115	25.39%
	Moderate Impairment	444	6	1.35%
	No Impairment	553	93	16.82%
	Very Mild Impairment	503	212	42.15%
GIST Descriptors	Mild Impairment	453	41	9.05%
	Moderate Impairment	444	0	0.00%
	No Impairment	553	29	5.24%
	Very Mild Impairment	503	68	13.52%
Hu Moment	Mild Impairment	453	59	13.02%
	Moderate Impairment	444	9	2.03%
	No Impairment	553	44	7.96%
	Very Mild Impairment	503	111	22.07%

Dari total 15.624 sampel yang diuji, terdapat 2.717 sampel yang salah diklasifikasikan atau sekitar 17,39% dari keseluruhan data, menunjukkan bahwa meskipun model memiliki performa tinggi secara umum, masih terdapat tantangan dalam memisahkan beberapa kelas yang memiliki karakteristik visual yang berdekatan.


Hasil dari error analysis menunjukkan bahwa tingkat kesalahan klasifikasi bervariasi tergantung pada jenis fitur yang digunakan dalam model XGBoost. Metode Gist Descriptor menunjukkan performa terbaik dengan tingkat kesalahan total paling rendah di antara semua metode. Sebaliknya, metode LBP menunjukkan performa terburuk dengan tingkat kesalahan tertinggi, khususnya pada kelas Very Mild Impairment yang mencapai 55,47%, diikuti Mild Impairment sebesar 35,10%. Ini menunjukkan bahwa fitur tekstur lokal dari LBP kurang efektif untuk membedakan tekstur halus antar tingkat gangguan kognitif.

Metode FFT, Wavelet, dan Zernike juga memiliki tingkat kesalahan yang cukup tinggi, terutama pada kelas Very Mild Impairment yang sulit diklasifikasikan dengan benar. Hal ini disebabkan oleh kemiripan visual antara kelas Very Mild Impairment dan Mild Impairment, yang menyebabkan tumpang tindih representasi fitur di ruang vektor.

Sementara itu, fitur HOG, Hu moment, dan GLCM menunjukkan performa yang stabil dengan tingkat kesalahan moderat. Ketiga metode ini relatif konsisten dalam mengenali kelas Moderate Impairment dengan kesalahan berada di bawah 3%, menandakan pola tekstur dan bentuk yang ditangkap cukup kuat untuk membedakan kelas.

Secara keseluruhan, hasil analisis memperlihatkan bahwa kesalahan klasifikasi sering terjadi pada kelas Very Mild Impairment, terlepas dari jenis fitur yang digunakan. Hal ini juga menandakan bahwa kelas tersebut memiliki karakteristik yang sulit dibedakan, sehingga di masa depan dapat menjadi fokus utama untuk perbaikan model atau pemilihan fitur yang lebih sensitif terhadap perbedaan halus antar tingkat gangguan.

c. Confusion Matrix



Gambar 3. Confusion Matrix

Berdasarkan Confusion Matrix Gabungan XGBoost (Semua Model) pada gambar 3, terlihat bahwa model secara umum memiliki performa klasifikasi yang baik, namun masih terdapat beberapa pola kesalahan yang menarik untuk dianalisis lebih dalam.

1. Kinerja Terbaik – Kelas Moderate Impairment:

Model menunjukkan kemampuan klasifikasi yang sangat baik pada kelas *Moderate Impairment*, dengan 3.484 sampel terklasifikasi benar, dan hanya sedikit kesalahan prediksi ke kelas lain (total misclass sekitar 68 sampel). Hal ini menunjukkan bahwa fitur yang digunakan oleh model mampu menangkap pola karakteristik yang jelas pada kelas ini.

2. Kelas No Impairment juga cukup akurat:

Sebagian besar data *No Impairment* (3.799 sampel) berhasil diklasifikasikan dengan benar. Namun, masih terdapat 519 sampel yang salah diklasifikasikan sebagai *Very Mild Impairment*, yang mengindikasikan adanya kemiripan fitur antara individu tanpa gangguan dan yang memiliki gangguan sangat ringan.

3. Kesalahan dominan pada kelas Mild dan Very Mild Impairment:

- a. Untuk *Mild Impairment*, sebanyak 370 sampel salah diklasifikasikan sebagai *No Impairment* dan 374 sebagai *Very Mild Impairment*. Ini menunjukkan bahwa batas antara *Mild* dan *Very Mild* sulit dipisahkan secara tegas oleh model.
- b. Kelas *Very Mild Impairment* memiliki tingkat kesalahan relatif tinggi, dengan 1.080 sampel terprediksi sebagai *No Impairment*. Ini merupakan sumber kesalahan terbesar di antara semua kelas, dan mengindikasikan bahwa fitur yang digunakan mungkin belum cukup sensitif untuk menangkap tanda-tanda awal gangguan yang sangat ringan.

4. Analisis Pola Kesalahan:

Pola kesalahan menunjukkan bahwa kesalahan klasifikasi paling sering terjadi antara kelas yang berdekatan secara klinis, misalnya *No Impairment* ↔ *Very Mild* dan *Mild* ↔ *Very Mild*. Ini wajar karena perbedaan karakteristik visual antara kategori tersebut cenderung halus, maka bisa terjadinya tumpang tindih.


5. Kesimpulan Umum:

Secara keseluruhan, model XGBoost menunjukkan performansi yang sangat baik untuk kelas *Moderate* dan *No Impairment*, tetapi masih perlu perbaikan dalam membedakan kelas dengan tingkat gangguan ringan. Pendekatan lanjutan seperti feature fusion (menggabungkan fitur GIST dan HOG) atau fine-tuning threshold klasifikasi mungkin dapat membantu meningkatkan akurasi pada kelas-kelas borderline seperti *Very Mild* dan *Mild Impairment*.

C. Deep Learning

Tahap 1: CNN Model

Convolutional Neural Network (CNN) adalah salah satu arsitektur deep learning yang dirancang khusus untuk memproses data berbentuk grid, terutama citra (gambar). CNN bekerja dengan memanfaatkan operasi convolution untuk mengekstraksi fitur-fitur penting dari gambar, seperti tepi, bentuk, tekstur, pola, hingga objek yang lebih kompleks. Dibandingkan neural network biasa (fully connected network), CNN lebih efisien karena tidak membutuhkan jumlah parameter yang sangat besar dan mampu menangkap struktur spasial dalam sebuah gambar.



Gambar 4: Pipeline CNN

Sebagai bagian dari proses pengolahan citra berbasis deep learning, Convolutional Neural Network (CNN) memproses gambar melalui serangkaian tahapan untuk mengekstraksi dan mempelajari fitur secara otomatis. Alur umum kerja CNN digambarkan pada Gambar 4, di mana setiap tahapan berperan dalam mengubah citra mentah menjadi representasi fitur yang semakin abstrak dan bermakna.

- Gambar masuk sebagai piksel.
- CNN melakukan serangkaian *convolution* → mendeteksi pola sederhana.
- Di layer lebih dalam, CNN belajar pola yang lebih kompleks → bentuk objek.
- Fitur diringkas melalui *pooling*.
- Lapisan *fully connected* menentukan kelas akhir berdasarkan fitur yang dipelajari.

CNN belajar langsung dari data tanpa membutuhkan rekayasa fitur manual (*hand-crafted features*), sehingga cocok untuk berbagai tugas seperti klasifikasi gambar, deteksi objek, segmentasi, dan pengenalan wajah.

Tahap 2: Transformer

Transformer adalah arsitektur *deep learning* yang diperkenalkan awalnya untuk pemrosesan bahasa alami (*Natural Language Processing*), tetapi prinsipnya dapat diterapkan pada berbagai jenis data, termasuk citra. Transformer bekerja dengan menggunakan mekanisme *self-attention*, yang memungkinkan model untuk mempelajari hubungan antar elemen data secara global, bukan hanya lokal seperti pada CNN.

Dalam konteks pengolahan citra, Transformer memproses gambar dengan terlebih dahulu membagi citra menjadi elemen atau patch kecil, yang kemudian direpresentasikan sebagai vektor embedding. Setiap elemen dapat "memperhatikan" elemen lainnya melalui *self-attention*, sehingga Transformer dapat menangkap keterkaitan spasial global dalam gambar, pola kompleks, dan konteks antar objek.




Figure 1: The Transformer - model architecture.

Gambar 5: Pipeline Transformer

Sebagai bagian dari pengolahan citra berbasis Transformer, model Vision Transformer (ViT) memproses gambar melalui serangkaian tahapan untuk mengekstraksi dan mempelajari fitur secara global. Alur umum kerja Transformer digambarkan pada Gambar 5, di mana alur umum transformer (Encode-Encoder):

1. Input Embedding
 - Data masukan (misal patch citra atau token teks) diubah menjadi vektor embedding.
 - Positional encoding ditambahkan untuk mempertahankan informasi posisi.
2. Encoder (Nx Block)
 - Setiap blok encoder terdiri dari:
 - a. Multi-Head Attention → mempelajari hubungan global antar elemen input.
 - b. Add & Norm → penjumlahan residual + normalisasi layer.
 - c. Feed Forward → memproses informasi lebih lanjut melalui lapisan non-linear.
 - d. Add & Norm → residual connection tambahan.
 - Proses ini diulang sebanyak Nx layer untuk menangkap pola global secara mendalam.
3. Decoder (Nx Block)
 - Setiap blok decoder memiliki:
 - a. Masked Multi-Head Attention → memproses output sebelumnya, mencegah "melihat" token masa depan.
 - b. Add & Norm
 - c. Multi-Head Attention → menghubungkan output decoder dengan representasi dari encoder.
 - d. Add & Norm
 - e. Feed Forward
 - f. Add & Norm
4. Output Embedding → Linear → Softmax
 - Output embedding diubah melalui lapisan Linear.
 - Softmax digunakan untuk menghasilkan probabilitas kelas akhir (untuk klasifikasi citra) atau token output (untuk NLP).

Tahap 3: Arsitektur Model

Beberapa arsitektur deep learning yang digunakan untuk klasifikasi citra. Masing-masing model memiliki karakteristik dan pendekatan yang berbeda. Model yang digunakan meliputi:

1. CNN Scratch

ResNet50 adalah model CNN pre-trained yang populer dengan 50 lapisan dan menggunakan residual block. Konsep *residual learning* membantu mengatasi masalah vanishing gradient pada jaringan yang sangat dalam.

Setiap *residual block* memiliki koneksi skip connection, yang memungkinkan informasi dari lapisan sebelumnya dilewatkan langsung ke lapisan lebih dalam tanpa terganggu oleh transformasi non-linear. Keunggulan ResNet50:

- Mampu melatih jaringan sangat dalam tanpa degradasi performa.
- Stabil pada proses pelatihan.
- Cocok untuk *transfer learning* pada dataset spesifik.

2. ResNet50

ResNet50 adalah model CNN pre-trained yang populer dengan 50 lapisan dan menggunakan residual block. Konsep *residual learning* membantu mengatasi masalah vanishing gradient pada jaringan yang sangat dalam.

Setiap *residual block* memiliki koneksi skip connection, yang memungkinkan informasi dari lapisan sebelumnya dilewatkan langsung ke lapisan lebih dalam tanpa terganggu oleh transformasi non-linear. Keunggulan ResNet50:

- Mampu melatih jaringan sangat dalam tanpa degradasi performa.
- Stabil pada proses pelatihan.
- Cocok untuk *transfer learning* pada dataset spesifik.

3. EfficientNet

EfficientNet adalah arsitektur CNN modern yang mengoptimalkan scaling jaringan secara komprehensif: depth, width, dan resolusi input. Alih-alih memperbesar jaringan secara konvensional, EfficientNet menggunakan *compound scaling* untuk menyeimbangkan ketiga aspek tersebut, sehingga menghasilkan model yang lebih akurat dan efisien secara komputasi. Keunggulan EfficientNet:

- Presisi tinggi dengan jumlah parameter relatif kecil.
- Latihan lebih cepat dibanding model sekelas ResNet dengan performa setara.
- Cocok untuk deployment di perangkat dengan sumber daya terbatas.

4. ViT B/16 (Vision Transformer)

ViT B/16 adalah model Transformer untuk pengolahan citra. Berbeda dengan CNN, ViT membagi citra menjadi patch-patch kecil (16×16) yang diperlakukan sebagai token, kemudian diproses oleh Transformer encoder untuk mengekstrak fitur global.

Kelebihan ViT B/16:

- Mampu menangkap hubungan spasial global antar patch.
- Efektif pada dataset besar berkat self-attention mechanism.
- Memerlukan *pre-training* yang cukup untuk hasil optimal.

5. EfficientFormer

EfficientFormer adalah arsitektur hybrid CNN-Transformer yang menggabungkan efisiensi CNN dan kemampuan Transformer. Model ini memanfaatkan konvolusi ringan untuk ekstraksi fitur awal, lalu dilanjutkan dengan Transformer blocks untuk memodelkan interaksi global antar fitur.

Keunggulan:

- Performa tinggi dengan efisiensi komputasi lebih baik dibanding ViT murni.
- Latihan lebih cepat.
- Cocok untuk deployment dengan keterbatasan resource.

6. Swin Transformer


Swin Transformer adalah model hierarchical Vision Transformer yang menggunakan konsep shifted window untuk *self-attention*. Dengan mekanisme ini, Swin Transformer:

- Mengurangi kompleksitas komputasi dibanding ViT murni.
- Menangkap hubungan lokal dan global secara efisien.
- Mendukung ekstraksi fitur pada resolusi tinggi dan berbagai skala objek.

Swin Transformer banyak digunakan untuk klasifikasi citra, deteksi objek, dan segmentasi karena fleksibilitas dan performanya yang tinggi.

Tahap 4: Finetuning

Fine-tuning adalah proses menyesuaikan model *pre-trained* agar dapat bekerja optimal pada tugas atau dataset spesifik. Ada dua pendekatan yang umum digunakan: Full-Parameter Fine-Tuning dan Low-Rank Adaptation (LoRA) Fine-Tuning.



Gambar 6: Pipeline Finetuning

1. Full-Parameter Fine-Tuning

Pada full-parameter fine-tuning penuh, seluruh bobot dari model yang sudah dilatih sebelumnya (*pre-trained weights*) diperbarui selama proses pelatihan. Gambar di sebelah kiri menunjukkan alur kerjanya:

- Input Feature → melewati linear layer dengan bobot W_0 yang sudah *pre-trained*.
 - Selama *forward pass*, input diproses menjadi Output Feature.
 - Selama *backward pass*, seluruh bobot W_0 diperbarui berdasarkan *loss* dari tugas spesifik.
- a. Kelebihan:
- Model dapat menyesuaikan secara maksimal dengan dataset baru.
- b. Kekurangan:
- Membutuhkan komputasi tinggi dan memori besar, terutama untuk model besar seperti ResNet50 atau ViT.
 - Risiko overfitting jika dataset baru relatif kecil.

2. LoRA Fine-Tuning

Pada LoRA Fine-Tuning, hanya bagian tambahan berupa low-rank matrices (A dan B) yang diperbarui, sementara bobot asli W_0 tetap dibekukan. Gambar di sebelah kanan menunjukkan alurnya:

- Input Feature $\rightarrow$ melewati pre-trained linear layer W_0 tanpa perubahan bobot.
- Matriks low-rank A dan B ditambahkan secara paralel.
- Hasil penjumlahan ($W_0 + A \cdot B$) menghasilkan Output Feature.
- Selama *backward pass*, hanya A dan B yang diperbarui, sedangkan W_0 tetap sama.

a. Kelebihan:

- Hemat parameter: jumlah bobot yang dilatih jauh lebih sedikit.
- Efisien komputasi dan memori, cocok untuk model besar.
- Menyimpan pengetahuan pre-trained karena bobot asli tidak diubah.

b. Kekurangan:

- Tidak semua arsitektur kompatibel langsung
- Potensi overhead implementasi
- Performa mungkin lebih rendah

Tahap 5: Evaluasi

Dalam tahap evaluasi ini, performa berbagai arsitektur jaringan saraf dalam pengenalan citra Alzheimer dibandingkan menggunakan beberapa strategi fine-tuning. Fokus evaluasi mencakup model Convolutional Neural Networks (CNN) dan Transformers, dengan pengukuran akurasi pada dataset pengujian. Selain model baseline yang dilatih dari awal atau menggunakan bobot pre-trained, kami juga mengevaluasi dua pendekatan fine-tuning: Fine-Tuning Normal dan Low-Rank Adaptation (LoRA) Fine-Tuning. Tujuannya adalah untuk menilai seberapa efektif masing-masing strategi dalam meningkatkan performa model, menjaga stabilitas jaringan, serta mencegah overfitting pada dataset yang relatif terbatas.

Model	Training Strategy	Class	Precision	Recall	F1-Score	Accuracy
		Mild Impairment	97%	95%	96%	
		Moderate Impairment	100%	100%	100%	

CNN	Baseline	No Impairment	93%	94%	94%	95,29%
		Very Mild Impairment	92%	92%	92%	
ResNet50	Baseline	Mild Impairment	82%	69%	75%	72,67%
		Moderate Impairment	100%	97%	98%	
		No Impairment	63%	73%	67%	
		Very Mild Impairment	55%	54%	54%	
ResNet50	Fine-Tuning Normal	Mild Impairment	86%	84%	85%	78,40%
		Moderate Impairment	100%	98%	99%	
		No Impairment	86%	52%	65%	
		Very Mild Impairment	58%	86%	69%	
ResNet50	Fine-Tuning LoRA	Mild Impairment	97%	95%	96%	95,45%
		Moderate Impairment	100%	100%	100%	
		No Impairment	90%	99%	94%	

		Very Mild Impairment	97%	88%	93%	
EfficientNet	Baseline	Mild Impairment	97%	95%	96%	94,98%
		Moderate Impairment	100%	99%	100%	
		No Impairment	91%	97%	94%	
		Very Mild Impairment	94%	88%	91%	
EfficientNet	Fine-Tuning Normal	Mild Impairment	93%	96%	94%	93,09%
		Moderate Impairment	100%	99%	99%	
		No Impairment	90%	93%	91%	
		Very Mild Impairment	91%	86%	88%	
EfficientNet	Fine-Tuning LoRA	Mild Impairment	94%	96%	95%	94,27%
		Moderate Impairment	100%	99%	99%	
		No Impairment	91%	95%	93%	
		Very Mild Impairment	93%	87%	90%	

Swin Transformer	Baseline	Mild Impairment	96%	94%	95%	93,71%
		Moderate Impairment	100%	100%	100%	
		No Impairment	90%	94%	92%	
		Very Mild Impairment	90%	88%	89%	
Swin Transformer	Fine-Tuning Normal	Mild Impairment	95%	97%	96%	95,34%
		Moderate Impairment	100%	99%	100%	
		No Impairment	95%	93%	94%	
		Very Mild Impairment	92%	92%	92%	
Swin Transformer	Fine-Tuning LoRA	Mild Impairment	97%	93%	95%	94,73%
		Moderate Impairment	100%	100%	100%	
		No Impairment	93%	96%	94%	
		Very Mild Impairment	90%	91%	91%	
		Mild Impairment	98%	95%	97%	

EfficientFormer	Baseline	Moderate Impairment	100%	99%	100%	95,14%
		No Impairment	94%	94%	94%	
		Very Mild Impairment	90%	93%	92%	
EfficientFormer	Fine-Tuning Normal	Mild Impairment	94%	94%	94%	93,14%
		Moderate Impairment	100%	99%	99%	
		No Impairment	94%	89%	91%	
		Very Mild Impairment	86%	92%	89%	
EfficientFormer	Fine-Tuning LoRa	Mild Impairment	94%	95%	95%	94,73%
		Moderate Impairment	100%	100%	100%	
		No Impairment	95%	93%	94%	
		Very Mild Impairment	90%	92%	91%	
		Mild Impairment	99%	96%	97%	
		Moderate Impairment	100%	100%	100%	

ViT-B/16	Baseline	No Impairment	97%	93%	95%	96,26%
		Very Mild Impairment	91%	97%	94%	
ViT-B/16	Fine-Tuning Normal	Mild Impairment	97%	97%	97%	96,57%
		Moderate Impairment	100%	100%	100%	
		No Impairment	93%	98%	96%	
		Very Mild Impairment	97%	91%	94%	
ViT-B/16	Fine-Tuning LoRA	Mild Impairment	93%	95%	94%	92,78%
		Moderate Impairment	100%	100%	100%	
		No Impairment	96%	86%	91%	
		Very Mild Impairment	84%	92%	88%	

1. Convolutional Neural Networks (CNN)

Dari hasil evaluasi, terlihat bahwa performa model CNN bervariasi tergantung arsitektur dan strategi fine-tuning:

- CNN Scratch yang dilatih dari awal mencapai akurasi 95,29%, menunjukkan bahwa jaringan konvolusi sederhana sudah mampu menangkap fitur penting dari citra Alzheimer.

- ResNet50 baseline hanya mencapai 72,67%, namun dengan Fine-Tuning Normal meningkat menjadi 78,40%. Peningkatan signifikan terjadi ketika menggunakan LoRA Fine-Tuning, yang mencapai akurasi tertinggi 95,45%. Hal ini menunjukkan bahwa arsitektur residual ResNet50 sangat stabil untuk pelatihan, dan LoRA memungkinkan penyesuaian bobot secara efisien tanpa risiko overfitting, sehingga pelatihan menjadi lebih efektif.
- EfficientNet menunjukkan performa baseline yang tinggi (94,98%), namun fine-tuning normal menurun menjadi 93,09%, sedangkan LoRA Fine-Tuning sedikit menurun menjadi 94,27%. Hal ini mengindikasikan bahwa model EfficientNet sudah cukup optimal dalam konfigurasi pre-trained, dan fine-tuning tambahan hanya memberi dampak kecil.

Secara keseluruhan, ResNet50 dengan LoRA Fine-Tuning menjadi kombinasi terbaik di kategori CNN, karena mampu meningkatkan akurasi secara signifikan dibanding baseline maupun fine-tuning biasa.

2. Transformers


Pada arsitektur berbasis Transformer, hasil evaluasi menunjukkan tren yang berbeda:

- Swin Transformer baseline mencapai akurasi 93,71%, meningkat menjadi 95,34% dengan Fine-Tuning Normal, dan sedikit menurun ke 94,73% dengan LoRA Fine-Tuning. Hal ini menunjukkan bahwa Fine-Tuning Normal cukup efektif untuk meningkatkan representasi fitur Swin Transformer, sementara LoRA memberikan adaptasi yang lebih ringan namun sedikit mengorbankan akurasi.
- EfficientFormer baseline 95,14% menurun dengan Fine-Tuning Normal menjadi 93,14%, dan sedikit meningkat dengan LoRA Fine-Tuning menjadi 94,73%. Penurunan ini kemungkinan disebabkan oleh sensitivitas model terhadap overfitting saat fine-tuning biasa pada dataset yang relatif kecil.
- ViT B/16 menunjukkan akurasi tertinggi dengan Fine-Tuning Normal sebesar 96,57%, mengungguli baseline (96,26%) dan LoRA Fine-Tuning (92,78%). Hal ini menegaskan bahwa Vision Transformer sangat unggul dalam menangkap hubungan spasial antar patch citra secara global, dan Fine-Tuning Normal paling efektif menyesuaikan representasi fitur dengan dataset Alzheimer untuk prediksi yang lebih akurat.

Secara keseluruhan, untuk kategori Transformer, Fine-Tuning Normal lebih efektif daripada LoRA dalam meningkatkan akurasi, terutama pada model ViT B/16, meskipun LoRA tetap menawarkan adaptasi parameter yang lebih efisien.

Tahap 6: Error Analysis

1. CNN Baseline




Gambar 7: Confusion Matrix CNN Baseline

Confusion matrix ini menunjukkan bahwa model mampu mengklasifikasi sebagian besar kelas dengan sangat baik, terutama pada Moderate Impairment (443 benar, 0 salah) dan No Impairment (521 benar). Kesalahan yang muncul sebagian besar terjadi pada kelas yang memiliki batasan gejala yang mirip, seperti antara No Impairment dan Very Mild Impairment, terlihat dari 29 kasus “No Impairment” diprediksi sebagai “Very Mild Impairment”, dan 29 kasus sebaliknya.

Pola kesalahan ini menunjukkan bahwa model cenderung bingung pada kelas dengan perbedaan gejala yang sangat halus, sedangkan kelas yang karakternya lebih jelas seperti “Moderate Impairment” dikenali hampir sempurna. Ini wajar karena perbedaan fitur visual/klinikal antara kondisi ringan sering kali sangat kecil.

2. ResNet50 Baseline




Gambar 8: Confusion Matrix ResNet50 Baseline

Confusion matrix ini menunjukkan bahwa model cukup kuat dalam mengenali kelas Moderate Impairment dan No Impairment, ditandai dengan prediksi benar yang tinggi (431 dan 406). Namun, terdapat pola kesalahan yang cukup konsisten pada kelas yang berdekatan secara klinis. Misalnya, banyak kasus Very Mild Impairment diprediksi sebagai No Impairment (187 kasus), dan sebaliknya cukup banyak kasus No Impairment diprediksi sebagai Very Mild Impairment (125 kasus). Hal ini menunjukkan bahwa model masih kesulitan membedakan kategori dengan gejala sangat ringan.

Untuk kelas Mild Impairment, kesalahan terbesar adalah misclassify ke Very Mild Impairment (88 kasus) dan No Impairment (52 kasus). Ini mengindikasikan bahwa model cenderung “menurunkan tingkat keparahan” prediksi pada kondisi ringan. Secara keseluruhan, error terjadi terutama pada kelas yang batas gejalanya tipis, sementara kelas yang lebih jelas atau ekstrem terdeteksi dengan lebih stabil.

3. ResNet50 Fine-Tuning Normal




Gambar 9: Confusion Matrix ResNet50 Fine-Tuning Normal

Confusion matrix ini menunjukkan bahwa model fine-tuning normal bekerja sangat baik pada kelas dengan pola visual yang jelas, seperti Mild Impairment dan Moderate Impairment, keduanya memiliki prediksi benar yang tinggi (380 dan 433). Namun, model masih mengalami kesulitan membedakan kategori yang berdekatan secara klinis, terutama pada rentang No Impairment dan Very Mild Impairment. Hal ini terlihat dari banyaknya kasus No Impairment yang diprediksi sebagai Very Mild (240 kasus), serta sebaliknya banyak Very Mild diprediksi sebagai No Impairment (39 kasus).

Pola kesalahan ini menunjukkan bahwa batas visual antara kondisi sangat ringan dan normal sangat tipis, sehingga model sering “menggeser” prediksi ke kelas tetangga. Walaupun begitu, performa pada kelas dengan karakteristik lebih kuat tetap stabil, menandakan fine-tuning normal membantu model menangkap fitur pada kondisi yang lebih jelas dibandingkan kondisi borderline.

4. ResNet50 LoRA




Gambar 10: Confusion Matrix ResNet50 LoRA

Confusion matrix ini menunjukkan bahwa model LoRA FT memiliki kinerja yang sangat baik dalam mengklasifikasikan seluruh kelas, dengan sebagian besar prediksi berada pada diagonal (prediksi benar). Kelas Moderate Impairment dan No Impairment hampir sepenuhnya terklasifikasi dengan benar, masing-masing dengan 443 dan 546 prediksi tepat, menunjukkan bahwa model sangat yakin dan stabil pada dua kelas ini.

Kesalahan terbesar terjadi pada kelas Very Mild Impairment, di mana 50 sampel salah diprediksi sebagai No Impairment, serta pada kelas Mild Impairment yang memiliki beberapa mis-klasifikasi kecil ke arah kelas yang berdekatan (14 ke No Impairment dan 7 ke Very Mild). Pola ini menunjukkan bahwa kebanyakan error terjadi antar kelas yang tingkat impairment-nya berdekatan, yang wajar karena batasnya bisa sangat halus. Overall, model menunjukkan akurasi tinggi dengan error yang terkontrol dan konsisten.

5. EfficientNet Baseline




Gambar 11: Confusion Matrix EfficientNet Baseline

Confusion matrix EfficientFormer LoRA Fine-Tuned ini menunjukkan bahwa model bekerja sangat baik untuk semua kelas, dengan sebagian besar prediksi berada pada diagonal. Kelas Moderate Impairment dan No Impairment memiliki akurasi yang sangat tinggi (masing-masing 440 dan 538 prediksi benar), menandakan bahwa model mampu membedakan kedua kelas ini dengan konsisten.

Sebagian besar kesalahan muncul pada kelas yang tingkat impairment-nya berdekatan. Misalnya, Very Mild Impairment sering salah diprediksi sebagai No Impairment (46 sampel), dan Mild Impairment beberapa kali diprediksi menjadi Very Mild atau No Impairment. Pola ini menunjukkan bahwa ketika model melakukan error, biasanya terjadi pada kelas dengan gejala yang mirip, bukan pada kelas yang berbeda jauh. Secara keseluruhan, model menunjukkan performa tinggi dan kesalahan yang relatif kecil serta wajar.

6. EfficientNet Fine-Tuning Normal




Gambar 12: Confusion Matrix EfficientNet Fine-Tuning Normal

Confusion matrix EfficientNet Fine-Tuned menunjukkan performa yang tetap kuat, namun dengan pola error yang sedikit lebih besar dibanding model sebelumnya. Kelas Moderate Impairment dan Mild Impairment tetap terklasifikasi dengan sangat baik (437 dan 433 prediksi benar), menandakan signifikansi bahwa model mampu mengenali dua kelas ini secara stabil.

Kesalahan paling menonjol terjadi pada kelas Very Mild Impairment, yang cukup sering salah diprediksi sebagai Mild Impairment (26 sampel) atau No Impairment (44 sampel). Selain itu, kelas No Impairment juga memiliki error ke Very Mild (31 sampel). Ini menunjukkan bahwa model EfficientNet cenderung kesulitan membedakan kategori dengan gejala ringan dan berdekatan, sehingga boundary antar kelas tersebut tampak kurang tegas. Meskipun demikian, mayoritas prediksi tetap berada pada diagonal sehingga kinerja keseluruhan masih tergolong sangat baik.

7. EfficientNet LoRA




Gambar 13: Confusion Matrix EfficientNet Fine-Tuning LoRA

Confusion matrix EfficientNet LoRA menunjukkan performa model yang sangat kuat dengan sebagian besar prediksi berada tepat pada diagonal. Kelas Mild Impairment, Moderate Impairment, dan No Impairment masing-masing memiliki jumlah prediksi benar yang sangat tinggi (437, 437, dan 529), menandakan bahwa LoRA membantu EfficientNet mempertahankan akurasi tinggi dan konsistensi antar kelas utama.

Sebagian besar error kembali terjadi pada kelas Very Mild Impairment, yang cukup sering salah diprediksi sebagai Mild Impairment (19 sampel) atau No Impairment (46 sampel). Ini menunjukkan bahwa model masih kesulitan membedakan kategori dengan impairment sangat ringan, yang memang memiliki perbedaan visual yang tipis. Meski demikian, proporsi error keseluruhan tetap kecil sehingga model EfficientNet LoRA dapat dikatakan stabil dan akurat dalam tugas klasifikasi ini.

8. Swin Transformer Baseline




Gambar 14: Confusion Matrix Swin Transformer Baseline

Confusion matrix Swin Transformer Baseline menunjukkan performa yang sangat baik, terutama pada kelas Moderate Impairment dan No Impairment, masing-masing dengan 442 dan 522 prediksi benar. Hal ini menunjukkan bahwa model mampu mengenali pola pada dua kelas tersebut dengan konsisten, mirip dengan model-model sebelumnya.

Error terbesar kembali muncul pada kelas Very Mild Impairment, di mana 53 sampel salah diprediksi sebagai No Impairment, serta pada kelas Mild Impairment yang beberapa kali diprediksi sebagai Very Mild (22 sampel). Pola ini menunjukkan bahwa kesalahan paling umum terjadi pada kelas-kelas dengan tingkat impairment ringan yang berdekatan sehingga batas kategori sulit dibedakan. Meskipun begitu, mayoritas prediksi tetap akurat sehingga model baseline Swin Transformer memiliki performa keseluruhan yang solid.

9. Swin transformer Fine-Tuning Normal




Gambar 15: Confusion Matrix Swin Transformer Fine-Tuning Normal

Confusion matrix Swin Transformer Fine-Tuned menunjukkan performa sangat baik pada kelas Mild Impairment (441 benar), No Impairment (516 benar), dan Very Mild Impairment (466 benar), dengan akurasi tinggi pada ketiga kelas mayoritas ini.

Namun, model gagal total mendeteksi Moderate Impairment: hampir seluruhnya (440 dari 443 sampel) salah diprediksi sebagai Mild Impairment akibat kelas ini sangat under-represented. Hal ini menyebabkan model sangat bias ke kelas dominan dan tidak mampu mengenali Moderate Impairment sama sekali, meskipun akurasi keseluruhan tetap tinggi.

10. Swin transformer LoRA




Gambar 16: Confusion Matrix Swin Transformer Fine-Tuning LoRA

Confusion matrix LoRA-Enhanced Swin Transformer menunjukkan performa sangat baik pada kelas Moderate Impairment (441 prediksi benar, hampir sempurna), No Impairment (531 benar), dan Very Mild Impairment (459 benar). Model juga tetap kuat pada kelas Mild Impairment dengan 420 benar.

Dibandingkan model fine-tuned sebelumnya, LoRA berhasil mengatasi kegagalan deteksi Moderate Impairment secara drastis, dari nyaris 0 menjadi hampir 100% benar. Kesalahan utama kini hanya pada kebingungan ringan antar kelas berdekatan, seperti 34 Very Mild diprediksi No Impairment dan 26 Mild diprediksi Very Mild, yang wajar karena spektrum gangguannya mirip. Secara keseluruhan, LoRA-enhanced model jauh lebih seimbang dan akurat di semua kelas, terutama pada kelas Moderate yang sebelumnya bermasalah.

11. EfficientFormer Baseline




Gambar 17: Confusion Matrix EfficientFormer Baseline

Confusion matrix EfficientFormer Baseline menunjukkan performa sangat baik dan seimbang pada semua kelas utama: Mild Impairment (430 benar), Moderate Impairment (440 benar), No Impairment (518 benar), dan Very Mild Impairment (471 benar). Model berhasil mendeteksi Moderate Impairment dengan sangat baik, jauh lebih unggul dibandingkan Swin Transformer Fine-Tuned sebelumnya.

Kesalahan utama hanya terjadi pada transisi antar kelas ringan, seperti 33 Very Mild diprediksi sebagai No Impairment dan 30 No Impairment diprediksi sebagai Very Mild, serta 21 Mild diprediksi sebagai Very Mild — pola yang wajar karena tingkat gangguan yang berdekatan. Secara keseluruhan, EfficientFormer Baseline memberikan hasil paling akurat dan seimbang di antara model yang ada, dengan deteksi Moderate Impairment yang kuat dan distribusi error yang sangat minim.

12. EfficientFormer Fine-Tuning Normal




Gambar 18: Confusion Matrix EfficientFormer Fine-Tuning Normal

Confusion matrix EfficientFormer Fine-Tuned menunjukkan performa terbaik dan paling seimbang di antara semua model: Mild Impairment (425 benar), Moderate Impairment (438 benar), No Impairment (492 benar), dan Very Mild Impairment (465 benar), dengan diagonal dominan yang sangat kuat.

Kesalahan tetap rendah dan hanya terjadi pada kelas-kelas berdekatan (misalnya 46 No Impairment diprediksi Very Mild, 31 Very Mild diprediksi No Impairment, serta sedikit kebocoran ke Mild), yang mencerminkan kesulitan wajar pada gradasi gangguan ringan. Fine-tuning berhasil meningkatkan akurasi keseluruhan dan mempertahankan kemampuan deteksi Moderate Impairment yang sudah baik pada baseline, menjadikan EfficientFormer Fine-Tuned sebagai model dengan performa paling optimal dan paling konsisten di semua kelas.

13. EfficientFormer LoRA




Gambar 19: Confusion Matrix EfficientFormer Fine-Tuning LoRA

EfficientFormer LoRA Fine-Tuned confusion matrix menunjukkan performa paling optimal di seluruh eksperimen: Mild Impairment (430 benar), Moderate Impairment (441 benar, hampir sempurna), No Impairment (515 benar), dan Very Mild Impairment (465 benar), dengan nilai diagonal tertinggi dibanding semua model sebelumnya.

Kesalahan sangat minim dan hanya terjadi pada kelas-kelas ringan yang berdekatan (misalnya 31 No Impairment → Very Mild, 23 Very Mild → No Impairment, serta sedikit kebocoran ke Mild), sementara Moderate Impairment hampir tidak lagi bingung dengan kelas lain. Kombinasi LoRA dan fine-tuning pada EfficientFormer berhasil memberikan hasil paling seimbang, akurat, dan stabil, menjadikannya model terbaik dalam mendeteksi semua tingkat impairment, termasuk kelas Moderate yang sebelumnya sulit.

14. ViT B/16 Baseline




Gambar 20: Confusion Matrix ViT B/16 Baseline

Gambar 19: Confusion Matrix Vit B/16 Baseline

Confusion matrix ViT-B/16 Baseline menunjukkan performa sangat baik pada kelas Mild Impairment (435 benar), Moderate Impairment (442 benar), dan Very Mild Impairment (488 benar). Model ini juga mampu mendeteksi Moderate Impairment dengan akurat sejak baseline, tanpa kelemahan signifikan seperti pada Swin Transformer.

Kesalahan utama hanya terfokus pada kebingungan antara No Impairment dan Very Mild Impairment (37 No Impairment → Very Mild dan 13 Very Mild → No Impairment), yang wajar karena kedua kelas memiliki karakteristik visual yang sangat mirip. Secara keseluruhan, ViT-B/16 Baseline sudah sangat kuat dan seimbang sejak awal, dengan performa mendekati model-model EfficientFormer yang telah di-fine-tune atau dilengkapi LoRA.

15. ViT B/16 Fine-Tuning Normal




Gambar 21: Confusion Matrix ViT B/16 Fine-Tuning Normal

Confusion matrix ViT-B/16 Fine-Tuned menunjukkan performa hampir sempurna dan menjadi salah satu yang terbaik: Mild Impairment (440 benar), Moderate Impairment (442 benar), No Impairment (544 benar), dan Very Mild Impairment (461 benar), dengan nilai diagonal tertinggi di hampir semua kelas.

Kesalahan sangat kecil dan hanya terjadi pada batas kelas ringan (33 Very Mild → No Impairment dan sedikit ke Mild), sementara Moderate Impairment terdeteksi dengan akurasi mendekati 100%. Fine-tuning pada ViT-B/16 berhasil memperbaiki kebingungan antara No Impairment dan Very Mild secara signifikan dibanding baseline, menjadikannya model paling akurat, seimbang, dan konsisten di seluruh eksperimen.

16. ViT B/16 LoRA



Gambar 22: Confusion Matrix ViT B/16 Fine-Tuning LoRA

Confusion matrix ViT-B/16 LoRA Fine-Tuned menunjukkan performa sangat baik pada Mild (430 benar), Moderate (442 benar), dan Very Mild Impairment (462 benar), serta tetap kuat pada Moderate Impairment. Namun, terjadi peningkatan kebingungan antara No Impairment dan Very Mild Impairment (63 No → Very Mild dan 21 Very Mild → No), lebih tinggi dibanding ViT-B/16 Fine-Tuned tanpa LoRA.

Dibandingkan dengan varian Fine-Tuned biasa, penambahan LoRA justru sedikit menurunkan ketajaman pemisahan antara No dan Very Mild Impairment, meskipun tetap mempertahankan akurasi tinggi pada kelas lainnya. Secara keseluruhan, model ini masih sangat baik, tetapi ViT-B/16 Fine-Tuned tanpa LoRA lebih unggul dalam menangani batas antara No dan Very Mild Impairment.

17. Strategi Mengurangi Misclassification

Misclassification yang dominan antara kelas “No Impairment” dan “Very Mild Impairment” menunjukkan bahwa model kesulitan menangkap perbedaan fitur yang sangat halus. Beberapa strategi berikut dapat digunakan untuk meningkatkan pemisahan antarkelas tersebut:

1. Class Weighting atau Focal Loss

Berikan bobot lebih tinggi (misalnya 2–3×) pada kedua kelas yang sering tertukar sehingga model lebih sensitif terhadap kesalahan pada boundary kelas. Alternatifnya, gunakan *focal loss* untuk menekankan sampel yang sulit diklasifikasikan.

2. Targeted Data Augmentation pada Kelas yang Membingungkan

Terapkan augmentasi ringan seperti noise kecil, gaussian blur, atau penurunan kontras hanya pada kelas “No Impairment” dan “Very Mild Impairment”. Pendekatan ini membantu model mempelajari fitur-fitur subtil yang membedakan keduanya.

3. Label Smoothing atau Soft Borderline Labels

Untuk sampel yang berada di area borderline, gunakan label lunak (misalnya No Impairment $\rightarrow [0.9, 0.1, 0, 0]$) agar model tidak terlalu overconfident dan dapat menangani ketidakpastian antar kelas.

4. Contrastive Learning (Triplet Loss / Contrastive Loss)

Tambahkan loss tambahan seperti triplet loss atau contrastive loss untuk memaksa embedding kedua kelas memiliki margin yang lebih jelas, mempertegas perbedaan representasi fitur.

5. Oversampling dan Mixup/CutMix Spesifik Antar Kelas Mirip

Oversampling sampel dari kedua kelas kemudian lakukan mixup atau cutmix hanya di antara dua kelas tersebut. Teknik ini mengajarkan model representasi transisi antar kelas sehingga prediksi menjadi lebih stabil.

6. Tuning Threshold Confidence

Sesuaikan ambang probabilitas, misalnya hanya menerima prediksi “Very Mild Impairment” jika confidence > 0.6 . Teknik ini dapat membantu mengurangi prediksi ragu-ragu yang semestinya masuk kategori “No Impairment”.

Dengan mengombinasikan 2–3 teknik di atas, terutama class weighting, augmentasi terarah, dan focal loss biasanya tingkat kesalahan silang antara dua kelas yang mirip dapat ditekan hingga 50–80% tanpa mengorbankan performa kelas lain.